



Universidad Autónoma de San Luis Potosí

Facultad de Ciencias Químicas

Proyecto de Investigación

Modelos de Reacción–Difusión acoplada a una red metabólica asociada
al cáncer de mama

Autor: Alejandro Guerra González

Asesor: Dr. Erik César Herrera Hernández

1. Resumen

Este proyecto propone un marco integrado de biología de sistemas para investigar las redes metabólicas del cáncer de mama mediante la combinación de: (1) caracterización topológica como redes complejas, (2) modelado dinámico mediante sistemas de ecuaciones diferenciales ordinarias (SEDO), (3) análisis de sensibilidad paramétrica, y (4) aplicación de la teoría de patrones de Turing mediante la construcción de un Atlas de Turing. El objetivo final es identificar mecanismos de control críticos y patrones espaciales emergentes con potencial relevancia terapéutica.

En particular, el concepto de robustez se abordará como la capacidad de la red metabólica para mantener su funcionalidad frente a perturbaciones paramétricas y estructurales, evaluada mediante análisis de sensibilidad global y simulaciones Monte Carlo.

2. Introducción y Justificación

El cáncer de mama es una de las principales causas de mortalidad oncológica a nivel mundial. En 2024, el cáncer de mama fue la primera causa de muerte entre los tumores malignos en México (INEGI, 2025); el 99.2 % ocurrieron en mujeres. Esta enfermedad se caracteriza por una heterogeneidad molecular, clínica y metabólica que complica su tratamiento y pronóstico. Una de las características distintivas de las células cancerosas es la reprogramación metabólica, mediante la cual estas alteran su metabolismo para sostener la proliferación descontrolada, la supervivencia en condiciones adversas y la invasión tisular [1].

Las redes metabólicas son sistemas dinámicos y adaptativos cuyas propiedades emergentes no pueden comprenderse únicamente mediante enfoques reduccionistas. La topología de estas redes influye directamente en su funcionamiento, robustez y capacidad de respuesta a perturbaciones [2]. Sin embargo, la caracterización estructural resulta insuficiente para explicar la aparición de patrones espaciales y temporales observados en tumores [3, 4].

Desde el punto de vista teórico, la robustez, modularidad y jerarquía de las redes complejas se interpretan como propiedades emergentes que influyen directamente en la estabilidad dinámica del sistema metabólico y su capacidad adaptativa.

En este contexto, la teoría de patrones de Turing ofrece un marco matemático poderoso para entender cómo sistemas homogéneos pueden desarrollar patrones espaciales estables a partir de interacciones entre componentes con diferentes tasas de difusión. La hipótesis central plantea que las redes metabólicas del cáncer de mama pueden exhibir inestabilidades de Turing que conduzcan a patrones espaciales de concentración de metabolitos [5, 6].

3. Antecedentes

3.1. La reprogramación metabólica como sello distintivo del cáncer

La reprogramación metabólica es reconocida como uno de los sellos distintivos del cáncer, ya que permite a las células tumorales satisfacer las demandas energéticas, biosintéticas y redox necesarias para sostener una proliferación acelerada y sobrevivir en microambientes adversos. Este fenómeno implica alteraciones coordinadas en múltiples rutas metabólicas, incluyendo glucólisis aeróbica (efecto Warburg), metabolismo de glutamina, biosíntesis de lípidos y regulación del balance redox [1, 7].

En el cáncer de mama, la reprogramación metabólica presenta una fuerte dependencia del subtipo molecular y del contexto microambiental. Estudios experimentales han demostrado que diferentes subtipos exhiben perfiles metabólicos diferenciados, asociados a variaciones en la actividad mitocondrial, uso de nutrientes alternativos y adaptación a hipoxia [4]. Estas adaptaciones no son resultado de cambios aislados, sino de la reorganización global de redes metabólicas interconectadas.

Desde la perspectiva de ingeniería química, estas modificaciones pueden interpretarse como cambios en la topología y en los parámetros cinéticos de un sistema dinámico, lo que motiva la necesidad de modelos que integren múltiples escalas y rutas metabólicas de manera simultánea.

3.2. La perspectiva de redes complejas en biología de sistemas

La biología de sistemas propone que las propiedades funcionales de los sistemas biológicos emergen de la interacción no lineal entre sus componentes, más que de la acción aislada de elementos individuales. En este marco, las redes complejas proporcionan una representación formal para estudiar la organización estructural de sistemas metabólicos, donde los nodos representan metabolitos o enzimas y las aristas representan interacciones bioquímicas [2].

Las redes metabólicas presentan propiedades características de sistemas complejos, tales como distribución de grado heterogénea, modularidad, jerarquía y presencia de hubs altamente conectados. En cáncer, estas propiedades se ven alteradas por mutaciones, cambios epigenéticos y regulación aberrante, lo que conduce a una redistribución de flujos metabólicos y a una mayor robustez frente a perturbaciones externas [8].

Sin embargo, los análisis basados exclusivamente en métricas topológicas son inherentemente estáticos y no capturan la dinámica temporal ni la respuesta del sistema ante perturbaciones paramétricas. Por ello, es necesario complementar la caracterización estructural con modelos dinámicos que permitan estudiar estabilidad, transiciones dinámicas y control metabólico.

3.3. Estudio dinámico de las especies

El estudio dinámico de redes metabólicas se realiza comúnmente mediante sistemas de ecuaciones diferenciales ordinarias que describen la evolución temporal de las concentraciones de metabolitos en función de las tasas de reacción. Estos modelos se construyen a partir de la matriz estequiométrica y leyes cinéticas que reflejan los

mecanismos bioquímicos subyacentes [9].

En el contexto del cáncer, los modelos dinámicos permiten analizar la estabilidad de estados estacionarios, la aparición de oscilaciones metabólicas y la respuesta a perturbaciones farmacológicas. No obstante, el tamaño y la complejidad de las redes metabólicas reales conducen a sistemas de alta dimensión, con un gran número de parámetros cinéticos poco conocidos, lo que dificulta su análisis directo [10].

Esta limitación ha impulsado el desarrollo de técnicas de reducción de modelos, tales como separación de escalas de tiempo y renormalización, que permiten conservar la dinámica esencial del sistema mientras se reduce su complejidad computacional.

3.4. Necesidad de modelos espaciotemporales

Los tumores sólidos presentan una marcada heterogeneidad espacial debido a gradientes de oxígeno, nutrientes, pH y señales mecánicas en el microambiente tumoral. Estos gradientes generan regiones metabólicamente diferenciadas dentro del mismo tumor, lo que influye en la proliferación celular, la resistencia a fármacos y la progresión tumoral [3, 11].

Los modelos puramente temporales no son capaces de capturar esta heterogeneidad espacial. En contraste, los modelos de reacción-difusión basados en ecuaciones en derivadas parciales permiten describir simultáneamente la cinética local de las reacciones metabólicas y el transporte espacial de metabolitos mediante difusión efectiva.

Desde una perspectiva de ingeniería química, estos modelos son análogos a sistemas de reacción-difusión utilizados en procesos catalíticos y transporte en medios porosos, lo que proporciona un marco matemático bien establecido para el análisis de patrones espaciales emergentes.

3.5. La teoría de Turing

La teoría de patrones de Turing establece que un sistema dinámico puede desarrollar patrones espaciales estables a partir de un estado homogéneo cuando la interacción entre reacción y difusión induce una inestabilidad selectiva de ciertos modos espaciales [6]. Este mecanismo requiere, en general, la interacción entre especies con funciones opuestas (activador-inhibidor) y coeficientes de difusión significativamente diferentes.

Desde su formulación original, la teoría de Turing ha sido aplicada exitosamente para explicar patrones en biología del desarrollo, como la formación de rayas y man-

chas en tejidos [12]. Más recientemente, se ha propuesto que mecanismos análogos podrían operar en sistemas metabólicos, donde metabolitos o señales bioquímicas desempeñan roles funcionales diferenciados.

En el contexto del cáncer, la aplicación de la teoría de Turing ofrece una vía novedosa para entender la emergencia de heterogeneidad metabólica espacial como un fenómeno dinámico autoorganizado, en lugar de una simple consecuencia pasiva del microambiente.

3.6. Oportunidad de innovación

A pesar de los avances en el análisis estructural y dinámico de redes metabólicas, existe una brecha significativa en la integración sistemática de redes complejas, reducción de modelos y teoría de patrones en el estudio del cáncer. En particular, no se ha explorado de manera exhaustiva la posibilidad de que redes metabólicas completas exhiban inestabilidades de Turing bajo condiciones fisiológicamente plausibles.

Este proyecto propone abordar esta brecha mediante un enfoque integrador que combina caracterización topológica, modelado dinámico reducido, análisis de sensibilidad y extensión espaciotemporal. La construcción de un Atlas de Turing metabólico representa una contribución conceptual y metodológica innovadora, con el potencial de generar nuevas hipótesis sobre control metabólico, heterogeneidad tumoral y posibles blancos terapéuticos.

4. Objetivos

Hipótesis

La interacción no lineal entre metabolitos claves de cáncer de mamas, junto con diferencias en escalas de difusión, puede dar lugar a inestabilidades tipo Turing responsable de patrones espaciales observados en tumores.

Objetivo General

Diseñar y simular un modelo dinámico de reacción-difusión de la red metabólica del cáncer de mama, a partir de su representación como red compleja y su conversión en un sistema de ecuaciones diferenciales, con el fin de identificar condiciones paramétricas que generen inestabilidades de Turing y patrones espaciales emergentes en la distribución de metabolitos.

Objetivos Específicos

1. **Reconstruir y caracterizar topológicamente la red metabólica del cáncer de mama como un sistema complejo, identificando sus módulos funcionales y nodos críticos (hubs y conectividad).**

Procedimiento:

1. **Reconstrucción de la Red:** Se utilizará la base de datos genómica KEGG, específicamente los datos de cáncer de mama para construir un modelo metabólico a escala genómica, representado como un grafo dirigido donde los nodos son metabolitos y las aristas son reacciones catalizadas por enzimas [13, 14].
2. **Análisis Topológico:** Empleando NetworkX, se calcularán métricas estructurales clave [15, 16]:
 - **Grado (Degree):** Para identificar metabolitos altamente conectados (hubs) [2].
 - **Intermediación (Betweenness Centrality):** Para detectar nodos que actúan como conectores esenciales entre módulos (cuellos de botella) [17].
 - **Coeficiente de Agrupamiento (Clustering Coefficient):** Para evaluar la modularidad y la tendencia a formar "cliques" funcionales [18].
3. **Análisis de Comunidades:** Se aplicará el algoritmo de Louvain para descomponer la red en módulos o comunidades altamente interconectadas, correspondientes a vías metabólicas coordinadas [19].

2. **Desarrollar un modelo dinámico determinista de la red, basado en un Sistema de Ecuaciones Diferenciales Ordinarias (SEDO), que describa la cinética de las concentraciones metabólicas.**

Procedimiento:

1. **Derivación del Sistema de EDO:** El procedimiento parte directamente de la matriz de estequiometría de la red metabólica. Cada reacción se traduce en términos cinéticos, y la suma ponderada de flujos entrantes y salientes define la dinámica temporal de cada metabolito.
2. **Sistema de ecuaciones diferenciales ordinarias:** A partir de las relaciones entre los nodos (aristas), se construirá un sistema de ecuaciones diferenciales ordinarias para la red completa.

3. **Selección del Subconjunto Crítico:** A partir de los nodos críticos y módulos identificados en el Objetivo 1, se seleccionará un subconjunto de metabolitos y reacciones centrales para el modelado dinámico detallado (ej., vía glicolítica, ciclo de Krebs, metabolismo de glutamina). Serán comparados los resultados de ambos SEDO.
4. **Formulación de cada SEDO:** Para cada metabolito X_i , se planteará una ecuación de balance de masa [9]:

$$\frac{dX_i}{dt} = \sum_{j=1}^m S_{ij} V_j(\mathbf{X}, \mathbf{p})$$

donde S_{ij} es la matriz estequiométrica y V_j representa la ley de velocidad de cada reacción (ej., cinética de Michaelis-Menten, acción de masas, etc.) [10].

5. **Estimación de Parámetros:** Los parámetros cinéticos ($\mathbf{p}$) se obtendrán de bases de datos (BRENDA, SABIO-RK) y literatura especializada [20, 21]. En caso de datos faltantes, se emplearán algoritmos de ajuste por optimización (ej., mínimos cuadrados) utilizando datos de estado estacionario de la red [22].

3. Realizar un análisis de sensibilidad paramétrica global del SEDO para cuantificar la influencia de cada parámetro cinético en el comportamiento del sistema y priorizar aquellos con mayor impacto.

Procedimiento:

1. **Muestreo del Espacio Paramétrico:** Se utilizará el método de Saltelli para generar un conjunto amplio y representativo de combinaciones de parámetros dentro de rangos fisiológicamente plausibles [23].
2. **Análisis de Sensibilidad de Sobol:** Se aplicará este método de sensibilidad global basado en varianza para calcular [24, 25]:
 - **Índices de Sobol de primer orden:** Miden la contribución directa de cada parámetro a la varianza de la salida (ej., concentración de un metabolito clave).
 - **Índices de Sobol totales:** Miden la contribución total de cada parámetro, incluyendo sus interacciones con otros.
3. **Ranking de Sensibilidad:** Los parámetros se clasificarán según sus índices totales, identificando los **parámetros clave** (los más influyentes) que serán candidatos para el estudio de patrones de Turing.

4. Construir y resolver un modelo de reacción-difusión (EDP) para pares de metabolitos candidatos, con el fin de identificar condiciones que satisfagan los criterios de inestabilidad de Turing.

Procedimiento:

1. **Selección de Pares Candidatos:** Basándose en el análisis topológico (Objetivo 1) y el ranking de sensibilidad (Objetivo 3), se seleccionarán pares de metabolitos que cumplan roles potenciales de **activador** (metabolito autocatalítico o de corto alcance) e **inhibidor** (metabolito de largo alcance o que suprima la producción del activador), inspirándose en principios bioquímicos [12].
2. **Formulación del Modelo de Turing:** Para un par (u, v) , se planteará el sistema clásico de reacción-difusión [26]:

$$\begin{aligned}\frac{\partial u}{\partial t} &= f(u, v) + D_u \nabla^2 u \\ \frac{\partial v}{\partial t} &= g(u, v) + D_v \nabla^2 v\end{aligned}$$

donde f y g son las funciones de reacción no lineal derivadas del SEDO, y D_u , D_v son sus coeficientes de difusión efectivos.

3. **Análisis de Linealización y Condiciones de Turing:**

- Se linealizará el sistema alrededor de su estado estacionario homogéneo.
- Se calculará el Jacobiano y se analizará su espectro.
- Se verificará matemáticamente la **condición de Turing**: el estado homogéneo debe ser estable en ausencia de difusión (todos los autovalores del Jacobiano con parte real negativa), pero debe volverse inestable para algún número de onda $k > 0$ cuando $D_v \gg D_u$ [27, 28].

5. Realizar un barrido paramétrico sistemático y simulaciones numéricas para generar un ".Atlas de Turing" que catalogue los patrones espaciales emergentes (manchas, rayas, híbridos) en función de los parámetros clave del sistema.

Procedimiento:

1. **Barrido Paramétrico:** Se variarán sistemáticamente los parámetros clave identificados (ej., tasas de producción/degradación, coeficientes de difusión) en un rango amplio. Para cada combinación, se verificará numéricamente el cumplimiento de las condiciones de Turing.

2. **Simulación Numérica de Patrones:** En las regiones del espacio de parámetros donde se cumplan las condiciones, se resolverán numéricamente las EDPs de reacción-difusión en dominios espaciales 1D y 2D. Se utilizarán métodos numéricos robustos implementados en bibliotecas de Python como `py-pde` (método de líneas) [29] o `Fipy` (volúmenes finitos).
3. **Clasificación y Catalogación:** Los patrones resultantes (perfiles de concentración espacial) se clasificarán morfológicamente (ej., manchas aisladas, rayas periódicas, patrones mixtos) siguiendo taxonomías establecidas en sistemas de Turing [12].
4. **Construcción del Atlas:** Se creará un mapa multidimensional (el Atlas de Turing) que relacione cada región del espacio de parámetros con el tipo de patrón emergente, sirviendo como un recurso predictivo de la heterogeneidad metabólica espacial esperada bajo distintas condiciones fisiológicas o patológicas. Este concepto de `.atlas` paramétrico está inspirado en trabajos de dinámica de sistemas complejos [30].

5. Metodología

Fase 1: Caracterización de Redes Complejas

La red genómica del cáncer de mama (entrada KEGG: `hsa05224`) disponible en la base de datos KEGG (Kyoto Encyclopedia of Genes and Genomes) es el punto de partida para este trabajo. Esta red genómica está organizada por subtipos moleculares, vías dominantes y consecuencias biológicas; por lo que describe el espacio biológico completo del cáncer de mama. Además representa un repositorio de interacciones moleculares y genómicas experimentalmente validadas que caracterizan las condiciones fisiológicas patológicas del cáncer de mama, incluyendo:

Cascadas de señalización oncogénicas (e.g., PI3K-AKT, MAPK, Wnt) Mecanismos de regulación transcripcional alterados Reprogramación metabólica asociada a la transformación maligna y progresión tumoral

Cada luminal representa una etapa de evolución de los tumores de mama que va desde la etapa temprana e intermedia donde existe una dependencia hormonal hasta las etapas avanzadas donde presenta un alto potencial invasivo, con alta inestabilidad genómica independiente. Esta red completa cuenta con 190 especies repartidas como muestra la tabla 1:

Los datos de la ruta se recuperaron utilizando la API REST de KEGG y se analizaron mediante códigos escritos en Python. El proceso de construcción involucra

Cuadro 1: Tabla 1: Clasificación de dianas terapéuticas en investigación oncológica

Tipo	Especies
Receptores y ligandos	~25
MAPK + PI3K	~25
Wnt / Notch	~18
Ciclo celular	~15
Transcripción	~8
Daño ADN	~12
Angiogénesis	~4
Total	$\approx 180-200$

varios pasos clave:

1. **Identificación de Nodos:** Se extrajeron todas las entidades moleculares dentro de hsa05224. Esto resultó en dos tipos distintos de nodos: (i) enzimas metabólicas y proteínas de señalización, identificadas por Orthología KEGG (KO) o identificadores de genes con prefijo 'hsa' (ej. hsa:3099 para HK2), y (ii) compuestos químicos y metabolitos, identificados por identificadores de Compuesto con prefijo 'cpd' (ej. cpd:C00031 para D-Glucosa).
2. **Definición de Aristas:** Las interacciones binarias entre nodos se definieron basándose en los datos relacionales dentro del archivo KGML (KEGG Markup Language). Se estableció una arista e_{ij} desde el nodo i al nodo j para representar una interacción bioquímica dirigida.
3. **Simplificación y Validación de la Red:** Para enfocarnos en la red de interacciones metabólicas central, los nodos sin conexiones al metabolismo central del carbono, metabolismo de aminoácidos o vías redox fueron revisados manualmente. Se excluyeron nodos aislados e interacciones no directamente relevantes para el flujo metabólico (ej. asociaciones de enfermedades puramente diagnósticas), asegurando la coherencia funcional de la red para el modelado dinámico.

Este flujo de trabajo produce una red compleja que comprende V nodos y E aristas. La red no es un simple mapa metabólico sino una red *metabólico-regulatoria* integrada, ya que incluye tanto las transformaciones metabólicas como las proteínas de señalización clave que las regulan.

5.0.1. Representación en Grafos

Para el análisis computacional, la red se formalizará como un grafo dirigido $G = (V, E)$, donde $V = \{v_1, v_2, \dots, v_{158}\}$ es el conjunto de vértices (nodos) y $E \subseteq V \times V$

es el conjunto de pares ordenados que representan aristas dirigidas. Cada arista $e_{ij} = (v_i, v_j) \in E$ significa una influencia bioquímica dirigida de v_i a v_j .

La conectividad del grafo se codifica en una matriz de adyacencia $\mathbf{A}$ de dimensiones $V \times V$, donde el elemento a_{ij} se define como:

$$a_{ij} = \begin{cases} 1 & \text{si existe una arista desde el nodo } i \text{ al nodo } j \\ 0 & \text{en caso contrario.} \end{cases}$$

Esta formalización matemática nos permite aplicar un conjunto de algoritmos de teoría de grafos pertenecientes a las bibliotecas de Python (**networkx**, **igraph**) para calcular métricas topológicas (grado, centralidad, longitudes de camino), detectar comunidades e identificar motivos críticos de red. El flujo de trabajo asegura que la red resultante sea un reflejo fiel de la biología del tumor y, simultáneamente, un modelo óptimo para la biología de sistemas. Esta integración proporciona una base robusta para descubrir vulnerabilidades estructurales con relevancia clínica y potencial farmacológico.

5.1. Detección de Comunidades en la red Metabólica

Para descubrir la organización funcional de la red metabólica del cáncer de mama, empleamos el algoritmo de Louvain, un método heurístico optimizado para identificar comunidades de alta modularidad en redes grandes. Este algoritmo opera a través de un proceso iterativo de dos fases que maximiza la métrica de modularidad Q , definida como:

$$Q = \frac{1}{2m} \sum_{i,j} \left[A_{ij} - \gamma \frac{k_i k_j}{2m} \right] \delta(c_i, c_j),$$

donde A_{ij} es el elemento de la matriz de adyacencia, k_i y k_j son los grados de los nodos i y j , m es el número total de aristas, γ es un parámetro de resolución que controla el tamaño de la comunidad, y $\delta(c_i, c_j)$ es igual a 1 si los nodos i y j pertenecen a la misma comunidad y 0 en caso contrario.

5.1.1. Implementación y Selección de Parámetros

El algoritmo procede de la siguiente manera: Primero, cada nodo se asigna a su propia comunidad. Luego, en una serie de iteraciones, cada nodo se mueve a la comunidad de sus vecinos si este movimiento aumenta la modularidad general Q . Posteriormente, se construye una nueva red donde los nodos representan las comunidades encontradas, y el proceso se repite iterativamente hasta lograr la modularidad

máxima. Utilizamos un parámetro de resolución $\gamma = 1,0$, que representa la suposición del modelo nulo estándar donde no existen diferencias en la detección de comunidades es particularmente grandes o pequeños. Esta elección de parámetro produjo una partición con modularidad óptima $Q = 0,42$, significativamente mayor que las expectativas de redes aleatorias ($Q_{\text{random}} \approx 0,12 \pm 0,03$), confirmando una fuerte estructura comunitaria más allá de la organización aleatoria.

Fase 2: Desarrollo del SEDO

El modelo reducido de ecuaciones diferenciales ordinarias (EDO) se derivó sistemáticamente del análisis topológico y funcional del núcleo metabólico. En lugar de intentar modelar los 158 componentes de la red, aplicamos dos estrategias para la obtención de un Sistema de Ecuaciones Diferenciales Ordinarios (SEDO), estos son:

5.1.2. Escalas de tiempo

La reducción del modelo dinámico también se abordará mediante el método de separación de escalas de tiempo, una técnica clásica en ingeniería química y biología de sistemas que permite simplificar sistemas dinámicos de alta dimensión cuando coexisten procesos que evolucionan a velocidades significativamente diferentes.

En redes metabólicas, esta condición surge de manera natural debido a la coexistencia de reacciones rápidas (por ejemplo, equilibrios enzimáticos o reacciones cuasi-instantáneas) y procesos lentos asociados a regulación metabólica, cambios en concentración de metabolitos clave o adaptación celular. Bajo esta premisa, el sistema dinámico general:

$$\frac{d\mathbf{X}}{dt} = \mathbf{S}\mathbf{v}(\mathbf{X}, \boldsymbol{\theta})$$

puede descomponerse en dos subconjuntos de variables:

$$\mathbf{X} = (\mathbf{X}_f, \mathbf{X}_s),$$

donde $\mathbf{X}_f$ representa las variables rápidas y $\mathbf{X}_s$ las variables lentas.

El sistema dinámico completo puede escribirse entonces como:

$$\begin{aligned} \varepsilon \frac{d\mathbf{X}_f}{dt} &= \mathbf{f}(\mathbf{X}_f, \mathbf{X}_s), \\ \frac{d\mathbf{X}_s}{dt} &= \mathbf{g}(\mathbf{X}_f, \mathbf{X}_s), \end{aligned}$$

donde $0 < \varepsilon \ll 1$ es un parámetro adimensional que cuantifica la separación entre

las escalas temporales.

En el límite $\varepsilon \rightarrow 0$, las variables rápidas alcanzan un estado cuasi-estacionario definido implícitamente por:

$$\mathbf{f}(\mathbf{X}_f, \mathbf{X}_s) = 0.$$

Esta relación permite expresar $\mathbf{X}_f$ como una función de las variables lentas:

$$\mathbf{X}_f = \phi(\mathbf{X}_s),$$

lo cual conduce a un sistema reducido que describe únicamente la dinámica lenta:

$$\frac{d\mathbf{X}_s}{dt} = \mathbf{g}(\phi(\mathbf{X}_s), \mathbf{X}_s).$$

La identificación de las variables rápidas y lentas se realizará combinando criterios bioquímicos y topológicos. En particular, se considerarán como candidatas a variables rápidas aquellas especies:

- Asociadas a reacciones con constantes cinéticas elevadas.
- Con alta conectividad local pero baja centralidad global.
- Que participen en ciclos metabólicos cerrados de equilibrio rápido.

Por el contrario, las variables lentas corresponderán a metabolitos reguladores, nodos con alta intermediación o especies que controlan flujos metabólicos intermodulares, ya que su dinámica gobierna la evolución global del sistema.

Desde el punto de vista matemático, este procedimiento preserva la estabilidad de los estados estacionarios relevantes y reduce el sistema a una dimensión manejable, manteniendo la estructura no lineal necesaria para el análisis de bifurcaciones e inestabilidades de tipo Turing. Además, el modelo reducido obtenido por escalas de tiempo servirá como uno de los candidatos principales para su extensión a ecuaciones de reacción-difusión en el espacio.

Finalmente, los resultados del modelo reducido serán comparados con los obtenidos mediante el método de renormalización, evaluando la coherencia dinámica, la capacidad predictiva y la sensibilidad paramétrica de ambos enfoques. Esta comparación permitirá seleccionar el esquema de reducción más adecuado para la construcción del Atlas de Turing metabólico.

5.1.3. Método de Renormalización

Como estrategia complementaria a la separación de escalas de tiempo, se empleará el método de renormalización para la reducción sistemática del sistema dinámico

asociado a la red metabólica. Este enfoque, inspirado en la teoría de grupos de renormalización aplicada a sistemas complejos, permite identificar variables colectivas o efectivas que capturan el comportamiento dinámico dominante del sistema sin necesidad de resolver explícitamente todas las ecuaciones microscópicas.

La idea central consiste en agrupar subconjuntos de nodos altamente interconectados —identificados previamente como comunidades metabólicas mediante el algoritmo de Louvain— y reemplazarlos por variables macroscópicas renormalizadas que representen el estado dinámico promedio del módulo. Matemáticamente, si una comunidad C_α está compuesta por un conjunto de metabolitos $\{X_i\}_{i \in C_\alpha}$, se define una variable efectiva:

$$Y_\alpha = \sum_{i \in C_\alpha} w_i X_i,$$

donde w_i son coeficientes de ponderación que reflejan la importancia topológica y funcional de cada nodo, tales como centralidad de intermediación, grado o flujo metabólico promedio.

El sistema original de ecuaciones:

$$\frac{d\mathbf{X}}{dt} = \mathbf{S}\mathbf{v}(\mathbf{X}, \boldsymbol{\theta})$$

se transforma, mediante esta proyección, en un sistema renormalizado de menor dimensión:

$$\frac{d\mathbf{Y}}{dt} = \mathbf{F}(\mathbf{Y}, \boldsymbol{\Theta}),$$

donde $\mathbf{Y}$ es el vector de variables efectivas y $\boldsymbol{\Theta}$ representa parámetros renormalizados que incorporan la dinámica interna de cada comunidad.

Este procedimiento preserva las propiedades dinámicas esenciales del sistema, tales como estabilidad de estados estacionarios, bifurcaciones e interacciones no lineales dominantes, mientras reduce significativamente la complejidad computacional. En particular, la renormalización permite:

- Eliminar grados de libertad redundantes o débilmente acoplados.
- Conservar la influencia de hubs metabólicos y cuellos de botella funcionales.
- Facilitar el acoplamiento posterior con modelos de reacción–difusión.

Desde una perspectiva bioquímica, las variables renormalizadas representan el comportamiento agregado de vías metabólicas completas (por ejemplo, glucólisis, metabolismo de glutamina o balance redox), lo que resulta especialmente adecuado para el estudio de patrones espaciales emergentes a escala tisular.

Finalmente, el sistema renormalizado será comparado cuantitativamente con el SEDO completo y con el modelo reducido por escalas de tiempo, evaluando la fidelidad dinámica mediante la comparación de estados estacionarios, respuestas transitorias y sensibilidad paramétrica. Este análisis permitirá seleccionar el modelo más adecuado para la construcción del Atlas de Turing metabólico.

Fase 3: Análisis de Sensibilidad

Dado que los modelos dinámicos de redes metabólicas involucran un gran número de parámetros cinéticos con incertidumbre inherente, se realizará un análisis de sensibilidad paramétrica global con el objetivo de cuantificar la influencia relativa de cada parámetro sobre el comportamiento dinámico del sistema y priorizar aquellos con mayor impacto funcional.

El análisis de sensibilidad cumple un doble propósito: *(i)* evaluar la robustez del sistema frente a perturbaciones paramétricas y *(ii)* identificar los parámetros clave que gobiernan la estabilidad, la aparición de inestabilidades y la generación de patrones espaciales en los modelos de reacción–difusión.

Muestreo del Espacio Paramétrico

El espacio de parámetros $\boldsymbol{\theta} = (\theta_1, \theta_2, \dots, \theta_p)$ se explorará mediante un muestreo global basado en el esquema de Saltelli, una extensión del muestreo de tipo Latin Hypercube que permite el cálculo eficiente de índices de sensibilidad de Sobol.

Para cada parámetro cinético se definirá un intervalo de variación fisiológicamente plausible, basado en datos experimentales reportados en la literatura y bases de datos especializadas (BRENDA, SABIO-RK). En ausencia de información directa, se considerarán variaciones de uno a dos órdenes de magnitud alrededor del valor nominal estimado.

El muestreo generará un conjunto de realizaciones $\{\boldsymbol{\theta}^{(k)}\}_{k=1}^N$, donde N será suficientemente grande para garantizar la convergencia estadística de los índices de sensibilidad.

Definición de Variables de Salida

Las salidas del modelo empleadas para el análisis de sensibilidad incluirán:

- Concentraciones estacionarias de metabolitos clave.
- Flujos metabólicos dominantes en estado estacionario.

- Autovalores del Jacobiano evaluado en el estado estacionario, como medida indirecta de estabilidad dinámica.

Estas métricas permiten vincular directamente la sensibilidad paramétrica con propiedades dinámicas relevantes para la aparición de inestabilidades de Turing.

Cálculo de Índices de Sobol

Se calcularán los índices de Sobol de primer orden S_i y totales S_{T_i} , definidos como:

$$S_i = \frac{\text{Var}_{\theta_i}(\mathbb{E}_{\theta_{\sim i}}[Y | \theta_i])}{\text{Var}(Y)}, \quad S_{T_i} = 1 - \frac{\text{Var}_{\theta_{\sim i}}(\mathbb{E}_{\theta_i}[Y | \theta_{\sim i}])}{\text{Var}(Y)},$$

donde Y representa una variable de salida del modelo, θ_i es el parámetro de interés y $\theta_{\sim i}$ denota el conjunto de parámetros restantes.

Los índices de primer orden cuantifican la contribución directa de cada parámetro a la varianza de la salida, mientras que los índices totales capturan tanto los efectos individuales como las interacciones no lineales entre parámetros.

Identificación y Priorización de Parámetros Clave

Los parámetros se clasificarán de acuerdo con sus índices de Sobol totales, identificando aquellos con mayor influencia global sobre la dinámica del sistema. Estos parámetros clave serán:

- Prioritarios para el análisis de inestabilidades de Turing.
- Candidatos para el barrido paramétrico en la construcción del Atlas de Turing.
- Indicadores de posibles puntos de control metabólico con relevancia biológica y terapéutica.

Asimismo, se evaluará la correlación entre sensibilidad paramétrica y propiedades topológicas de la red (grado, intermediación, pertenencia comunitaria), permitiendo establecer un vínculo cuantitativo entre estructura de red y control dinámico.

Relación con la Robustez del Sistema

Finalmente, el análisis de sensibilidad permitirá caracterizar la robustez del sistema metabólico frente a perturbaciones paramétricas, identificando regiones del espacio de parámetros donde la dinámica es estable y regiones cercanas a transiciones dinámicas críticas. Esta información será fundamental para interpretar la aparición de patrones espaciales como un fenómeno emergente asociado a la pérdida de estabilidad del estado homogéneo.

Fase 4: Construcción del Atlas de Turing

La fase final del proyecto consiste en la extensión espaciotemporal del modelo dinámico reducido mediante la formulación de sistemas de reacción–difusión, con el objetivo de identificar y caracterizar inestabilidades de tipo Turing en la red metabólica del cáncer de mama. Esta fase integra la información estructural, dinámica y paramétrica obtenida en las etapas anteriores para construir un marco predictivo de patrones espaciales emergentes.

Formulación del Modelo de Reacción–Difusión

A partir del sistema de ecuaciones diferenciales ordinarias reducido (obtenido por escalas de tiempo o renormalización), se seleccionarán pares o subconjuntos mínimos de variables dinámicas $\{u, v\}$ que representen metabolitos o variables efectivas con roles funcionales diferenciados. El modelo espaciotemporal se formulará como:

$$\frac{\partial u}{\partial t} = f(u, v; \boldsymbol{\theta}) + D_u \nabla^2 u, \quad \frac{\partial v}{\partial t} = g(u, v; \boldsymbol{\theta}) + D_v \nabla^2 v,$$

donde f y g corresponden a las funciones de reacción no lineales derivadas directamente del SEDO, y D_u , D_v son coeficientes de difusión efectivos que representan el transporte metabólico en el microambiente tumoral.

Los coeficientes de difusión se considerarán desiguales ($D_v \gg D_u$) para reflejar diferencias físicas y bioquímicas en movilidad molecular, tales como difusión facilitada, transporte activo o acoplamiento con el espacio extracelular.

Análisis de Estabilidad Lineal

Para cada sistema candidato, se identificará el estado estacionario homogéneo (u^*, v^*) resolviendo:

$$f(u^*, v^*) = 0, \quad g(u^*, v^*) = 0.$$

Posteriormente, el sistema se linealizará alrededor de dicho estado estacionario, obteniendo el Jacobiano:

$$J = \begin{pmatrix} \frac{\partial f}{\partial u} & \frac{\partial f}{\partial v} \\ \frac{\partial g}{\partial u} & \frac{\partial g}{\partial v} \end{pmatrix}_{(u^*, v^*)}.$$

La estabilidad del estado homogéneo en ausencia de difusión se verificará imponiendo las condiciones clásicas:

$$\text{tr}(J) < 0, \quad \det(J) > 0.$$

La incorporación de difusión conduce a una relación de dispersión dependiente del número de onda k , cuyos autovalores $\lambda(k)$ se analizarán para identificar rangos de $k > 0$ donde $\text{Re}(\lambda(k)) > 0$. La existencia de estos modos inestables constituye la condición matemática de una inestabilidad de Turing.

Barrido Paramétrico y Regiones de Inestabilidad

Utilizando los parámetros clave identificados en la Fase 3, se realizará un barrido sistemático del espacio paramétrico (θ, D_u, D_v) . Para cada combinación de parámetros se evaluará:

- Estabilidad del estado homogéneo sin difusión.
- Aparición de modos espaciales inestables inducidos por difusión.
- Tipo de bifurcación asociada a la pérdida de estabilidad.

Este análisis permitirá identificar regiones bien definidas del espacio de parámetros donde el sistema es susceptible a la formación de patrones espaciales.

Simulación Numérica de Patrones Espaciales

En las regiones del espacio paramétrico que satisfagan las condiciones de Turing, se resolverán numéricamente las ecuaciones de reacción–difusión en dominios espaciales unidimensionales y bidimensionales. Se emplearán métodos numéricos robustos, como el método de líneas o esquemas de volúmenes finitos, implementados en bibliotecas científicas de Python.

Las simulaciones se iniciarán a partir de perturbaciones espaciales pequeñas alrededor del estado homogéneo, permitiendo observar la autoorganización espontánea del sistema hacia patrones estacionarios o cuasi-estacionarios.

Clasificación y Construcción del Atlas de Turing

Los patrones espaciales obtenidos se clasificarán de acuerdo con su morfología dominante, tales como:

- Manchas aisladas (spots).
- Rayas periódicas (stripes).
- Patrones mixtos o transicionales.

Finalmente, se construirá el **Atlas de Turing metabólico**, definido como un mapeo multidimensional que asocia regiones del espacio de parámetros con los tipos de patrones espaciales emergentes. Este atlas funcionará como una herramienta predictiva que relaciona control metabólico, difusión y heterogeneidad espacial, proporcionando una interpretación mecanística de la organización metabólica intratumoral.

6. Resultados Esperados

- Caracterización topológica completa de la red metabólica.
- Modelo dinámico de la red.
- Ranking de parámetros sensibles.
- Atlas de Turing metabólico.

7. Impacto Esperado

El Atlas de Turing proporcionará un marco predictivo para la heterogeneidad metabólica intratumoral y nuevas hipótesis terapéuticas.

8. Consideraciones Éticas y Limitaciones

Proyecto computacional basado en datos públicos. Las principales limitaciones incluyen la escasez de datos cinéticos *in vivo*.

9. Referencias Bibliográficas

Referencias

- [1] Douglas Hanahan and Robert A. Weinberg. Hallmarks of cancer: The next generation. *Cell*, 144(5):646–674, 2011. doi: 10.1016/j.cell.2011.02.013.
- [2] Albert-László Barabási and Zoltán N. Oltvai. Network biology: Understanding the cell’s functional organization. *Nature Reviews Genetics*, 5(2):101–113, 2004. doi: 10.1038/nrg1272.

- [3] Robert A. Gatenby and Robert J. Gillies. Why do cancers have high aerobic glycolysis? *Nature Reviews Cancer*, 4(11):891–899, 2004. doi: 10.1038/nrc1478.
- [4] Jing Zhang, Natalia N. Pavlova, and Craig B. Thompson. Cancer cell metabolism: the essential role of the nonessential amino acid, glutamine. *The EMBO Journal*, 36(10):1302–1315, 2017. doi: 10.15252/emboj.201696151.
- [5] M. Brennan, A. L. Krause, E. Villar-Sepúlveda, and C. B. Prior. Pattern formation as a resilience mechanism in cancer immunotherapy. *Bulletin of Mathematical Biology*, 87(8), 2025. doi: 10.1007/s11538-025-01485-3.
- [6] Alan M. Turing. The chemical basis of morphogenesis. *Bulletin of Mathematical Biology*, 52(1):153–197, 1990. Reimpresión del trabajo original de 1952.
- [7] Natalia N. Pavlova and Craig B. Thompson. The emerging hallmarks of cancer metabolism. *Cell Metabolism*, 23(1):27–47, 2016. doi: 10.1016/j.cmet.2015.12.006.
- [8] O. Resendis-Antonio, J. L. Reed, S. Encarnación, J. Collado-Vides, and B. Ø. Palsson. Metabolic reconstruction and modeling of cancer. *Journal of Theoretical Biology*, 264(4):1250–1262, 2010. doi: 10.1016/j.jtbi.2010.03.020.
- [9] Wolfram Liebermeister, Elad Noor, Avi Flamholz, Dan Davidi, Jörg Bernhardt, and Ron Milo. A visual account of protein investment in cellular functions. *Proceedings of the National Academy of Sciences of the United States of America*, 111(23):8488–8493, 2014.
- [10] Athel Cornish-Bowden. *Fundamentals of enzyme kinetics*. Elsevier, 2013.
- [11] Harold M. Swartz and David K. Harrison, editors. *Oxygen Transport to Tissue XXXVI*, volume 812 of *Advances in Experimental Medicine and Biology*. Springer, New York, 2013.
- [12] Shigeru Kondo and Takashi Miura. Reaction-diffusion model as a framework for understanding biological pattern formation. *Science*, 329(5999):1616–1620, 2010. doi: 10.1126/science.1179047.
- [13] Elizabeth Brunk, Swagatika Sahoo, Daniel C Zielinski, Ali Altunkaya, Andreas Dräger, Nathan Mih, Francesco Gatto, Avlant Nilsson, German A Preciat Gonzalez, Maike K Aurich, et al. Recon3d enables a three-dimensional view of gene variation in human metabolism. *Nature Biotechnology*, 36(3):272–281, 2018.

- [14] Ron Caspi, Richard Billington, Ingrid M Keseler, Anamika Kothari, Markus Krummenacker, Peter E Midford, Wai Kit Ong, Suzanne Paley, Pallavi Subh-raveti, and Peter D Karp. The metacyc database of metabolic pathways and enzymes—a 2019 update. *Nucleic Acids Research*, 48(D1):D445–D453, 2020.
- [15] Aric A Hagberg, Daniel A Schult, and Pieter J Swart. *Exploring network structure, dynamics, and function using NetworkX*. Los Alamos National Lab.(LANL), Los Alamos, NM (United States), 2008.
- [16] Paul Shannon, Andrew Markiel, Owen Ozier, Nitin S Baliga, Jonathan T Wang, Daniel Ramage, Nada Amin, Benno Schwikowski, and Trey Ideker. Cytoscape: a software environment for integrated models of biomolecular interaction networks. *Genome Research*, 13(11):2498–2504, 2003.
- [17] Mike P Joy, Amy Brock, Donald E Ingber, and Sui Huang. High-betweenness proteins in the yeast protein interaction network. *Bioinformatics*, 21(suppl_1): i99–i107, 2005.
- [18] Duncan J Watts and Steven H Strogatz. Collective dynamics of ‘small-world’ networks. *Nature*, 393(6684):440–442, 1998.
- [19] Vincent D Blondel, Jean-Loup Guillaume, Renaud Lambiotte, and Etienne Le-febvre. Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, 2008(10):P10008, 2008.
- [20] Antje Chang, Lisa Jeske, Sandra Ulbrich, Julia Hofmann, Julia Koblitiz, Ida Schomburg, Meina Neumann-Schaal, Dieter Jahn, and Dietmar Schomburg. Brenda, the elixir core data resource in 2021: new developments and updates. *Nucleic Acids Research*, 49(D1):D498–D508, 2021.
- [21] Ulrike Wittig, Renate Kania, Martin Golebiewski, Michael Rey, Lei Shi, Lenne-ke Jong, Enkhjargal Algaa, Andreas Weidemann, Isabel Rojas, and Wolfgang Müller. Sabio-rk–database for biochemical reaction kinetics. *Nucleic Acids Research*, 40(D1):D790–D796, 2012.
- [22] Natalie J Stanford, Timo Lubitz, Kieran Smallbone, Edda Klipp, Pedro Mendes, and Wolfram Liebermeister. Systematic construction of kinetic models from genome-scale metabolic networks. *PloS One*, 8(11):e79195, 2013.
- [23] Michael D McKay, Richard J Beckman, and William J Conover. A comparison of three methods for selecting values of input variables in the analysis of output from a computer code. *Technometrics*, 21(2):239–245, 1979.

- [24] Ilya M Sobol. Global sensitivity indices for nonlinear mathematical models and their monte carlo estimates. *Mathematics and Computers in Simulation*, 55 (1-3):271–280, 2001.
- [25] Andrea Saltelli, Paola Annoni, Ivano Azzini, Francesca Campolongo, Marco Ratto, and Stefano Tarantola. Variance based sensitivity analysis of model output. design and estimator for the total sensitivity index. *Computer Physics Communications*, 181(2):259–270, 2010.
- [26] Alan M Turing. The chemical basis of morphogenesis. *Philosophical Transactions of the Royal Society of London. Series B, Biological Sciences*, 237(641): 37–72, 1952.
- [27] Tomás Alarcón, Helen M Byrne, and Philip K Maini. A cellular automaton model for tumour growth in inhomogeneous environment. *Journal of Theoretical Biology*, 225(2):257–274, 2004.
- [28] James D Murray. *Mathematical Biology: I. An Introduction*, volume 17. Springer Science & Business Media, 2012.
- [29] Anders Logg, Kent-Andre Mardal, and Garth Wells. *Automated solution of differential equations by the finite element method: The FEniCS book*, volume 84. Springer Science & Business Media, 2012.
- [30] Steven H Strogatz. *Nonlinear dynamics and chaos: with applications to physics, biology, chemistry, and engineering*. CRC press, 2015.